# Predviđanje koncentracije PM2.5 čestica primjenom modernih modela vremenskih serija i dekompozicije trenda

## 1 Opis problema

Kvalitet vazduha u urbanim sredinama direktno zavisi od složene interakcije između antropogenih faktora i meteoroloških prilika. Problem koji ovaj projekat rješava je predviđanje budućih vrijednosti PM2.5 čestica na osnovu istorijskih podataka, uz jasno razgraničenje varijacija u podacima.

Ključni pojam analize:

- **Sezonalnost:** Pravilni, periodični obrasci fiksne dužine. U ovom istraživanju fokus je na *godišnjoj sezonalnosti* (razlika između grejne sezone i ljetnjeg perioda) i *dnevnoj sezonalnosti* (varijacije u zavisnosti od jutarnjih i popodnevnih saobraćajnih špiceva).

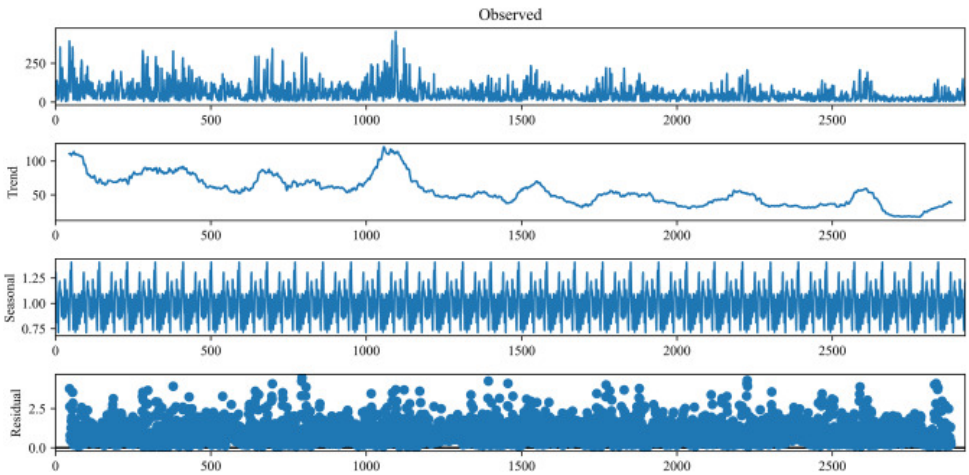


Slika 1: Primjer dekompozicije vremenske serije (Trend, Sezonalnost, Reziduali)

## 2 Skup podataka (Dataset)

**Izvor:** UCI Machine Learning Repository - Beijing Multi-Site Air-Quality.

**Opis skupa:** Skup obuhvata satna mjerenja zagađenja u periodu od **1. marta 2013. do 28. februara 2017. godine**. Ukupan broj mjerenja po svakoj od 12 mernih stanica iznosi **35,064 uzoraka**. Analiza će biti fokusirana na stanicu *Aotizhongxin*, koja sadrži podatke o PM2.5 koncentraciji, temperaturi, pritisku, vlažnosti vazduha i smjeru vjetra.

### Istraživačka pitanja

Tokom eksplorativne analize podataka (EDA), projekat će odgovoriti na sljedeća pitanja:

1. Koji meteorološki faktor (brzina vjetra, temperatura ili vlažnost) ima najjaču korelaciju sa skokovima zagađenja?
2. Postoji li jasan obrazac zagađenja u zavisnosti od doba dana ili u zavisnosti od doba godine?

# 3 Metodologija

### I Faza: Pretprocesiranje podataka

Podaci sadrže NaN vrijednosti koje nastaju usljed kvarova na senzorima. Primijeniće se linearna interpolacija za popunjavanje kratkih prekida, dok će se za duže periode koristiti sezonska zamjena srednjom vrijednošću.

### II Faza: Eksplorativna analiza i statistički testovi

Razlaganje serije na sezonalnost vršiće se pomoću `STL` dekompozicije. Stacionarnost će biti testirana Augmented Dickey-Fuller (ADF) testom.

### III Faza: Modelovanje (Poređenje modela)

Umjesto samo klasičnih metoda, implementiraće se i uporediti:

- **ARIMA (klasični model):** Kao osnovni statistički benchmark model.
- **Prophet (Meta):** Savremeni model otporan na nedostajuće vrijednosti i osjetljiv na praznike i višestruku sezonalnost (dnevnu i godišnju).
- **LSTM (Long Short-Term Memory):** Arhitektura dubokog učenja (RNN) specijalizovana za hvatanje nelinearnih zavisnosti u vremenskim serijama.

# 4 Svrha i cilj predikcije

Cilj projekta je **kratkoročna prognoza (short-term forecasting)** koncentracije PM2.5 čestica za narednih **24 sata**. Ovakav model ima praktičnu primjenu u sistemima ranog upozoravanja građana na opasne uslove kvaliteta vazduha.

# 5 Način evaluacije

Evaluacija će se vršiti na testnom skupu (posljednjih 6 mjeseci podataka). Koristiće se **RMSE** i **MAE** metrike.

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

# 6 Tehnologije

- **Programski jezik:** Python 3.x.
- **Biblioteke:** `Pandas`, `Statsmodels`, `Prophet`, `TensorFlow/Keras` (za LSTM).

# 7 Literatura


- Kaggle - Beijing Air Quality Analysis [Link].
- Air Quality Prediction using Machine Learning [Link].
- Istraživački rad (ScienceDirect): *Forecasting of Beijing PM2.5 with a hybrid ARIMA model....*